Sprawozdanie z projektu Evolutionary Computations

Autorzy

- Mateusz Bobula
- Norbert Dziwak
- Jakub Konopka

1. Technologie użyte w projekcie

- Python 3.12+
- PyQt6 do GUI
- benchmark-functions - funkcja testowa Hypersphere
- ruff - formater kodu
- uv - package manager

2. Wymagania środowiskowe

- Python 3.12
- venv z zainstalowanymi zależnościami z pyproject.toml
- uv

Uruchamianie aplikacji komendą uv run .\src\main.py

3. Opis wybranych funkcji testowych i ich optima

W aktualnej wersji aplikacji używana jest jedna funkcja testowa Hypersphere

Wzór funkcji:

$$f(x) = \sum_{i=1}^{N} x_i^2$$

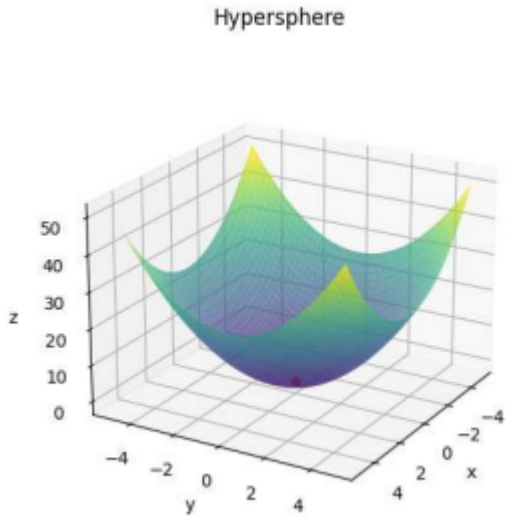

- Funkcja jest separowalna i wypukła

- Wartość funkcji jest nieujemna
- Minimum globalne występuje w punkcie x = (0,...,0)
- W minimum globalnym wartość funkcji wynosi f(x) = 0

4. Wykresy wyników

Projekt ma gotowy mechanizm zapisu i wizualizacji przebiegu optymalizacji

- Dla każdego uruchomienia tworzony jest osobny katalog wyników
- Zapisywany jest plik summary.json z konfiguracją i wynikiem końcowym
- Zapisywany jest plik history.csv z najlepszym fitness dla każdej epoki
- Generowany jest plik fitness_history.svg jako wykres historii fitness

Osadzone wykresy

Wspólny config dla wszystkich wykresów

Na podstawie plików summary.json wszystkie trzy przebiegi miały ten sam config bazowy

- Jedyna celowa zmiana między przebiegami to selection_method

Parametr	Wartość
function	Hypersphere
a	-5.0
b	5.0
dimensions	3
precision	6
population_size	50
epochs	175
crossover_method	single_point
crossover_prob	0.8
mutation_method	single_point
mutation_prob	0.01
inversion_prob	0.05
elite_size	1
minimize	true

Wykres 1

Wykres dla selekcji `tournament`

Kluczowa wartość configu względem pozostałych

- selection_method = tournament

Co widać na wykresie

- Najmocniejsza poprawa jakości w piersze kilka epok
- Potem dłuższa faza stabilizacji

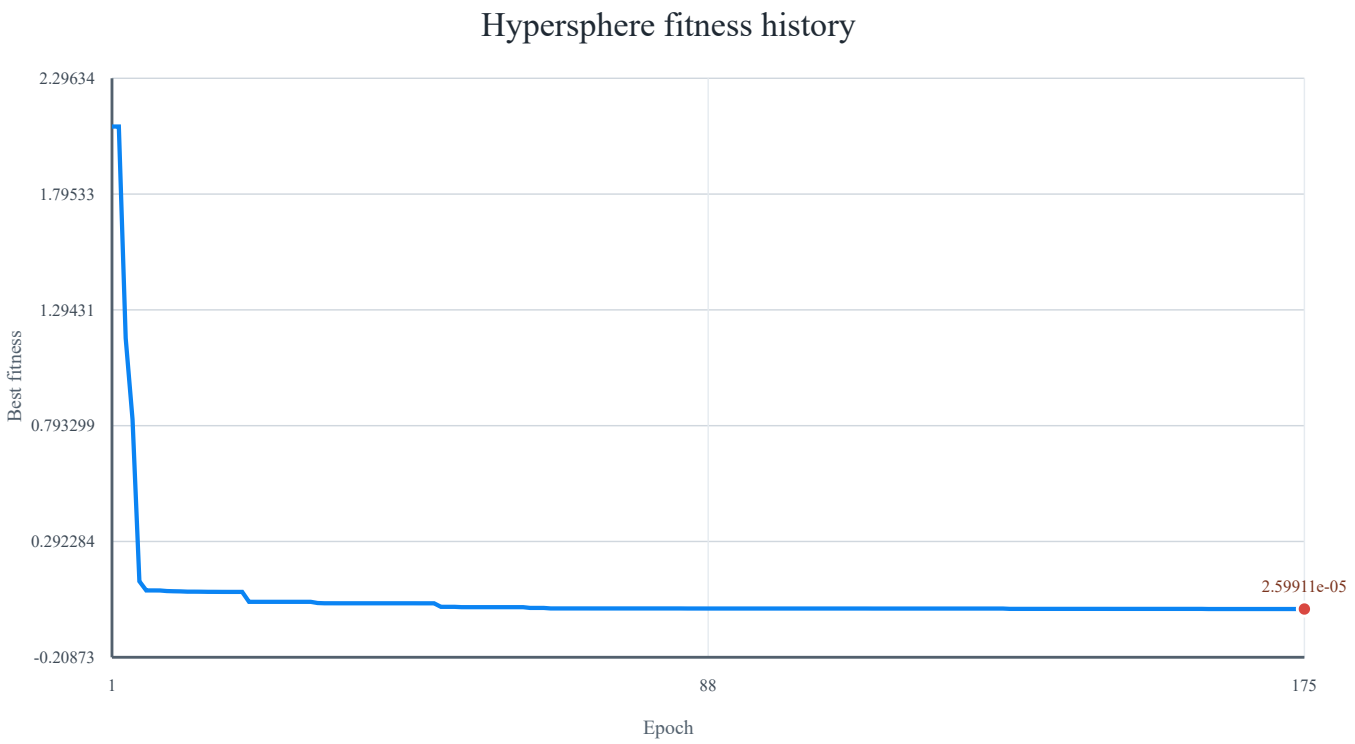

Wykres 2

Wykres dla selekcji `best`

Kluczowa wartość configu względem pozostałych

- selection_method = best

Co widać na wykresie

- Szybkie dojście schodkowe do wyniku

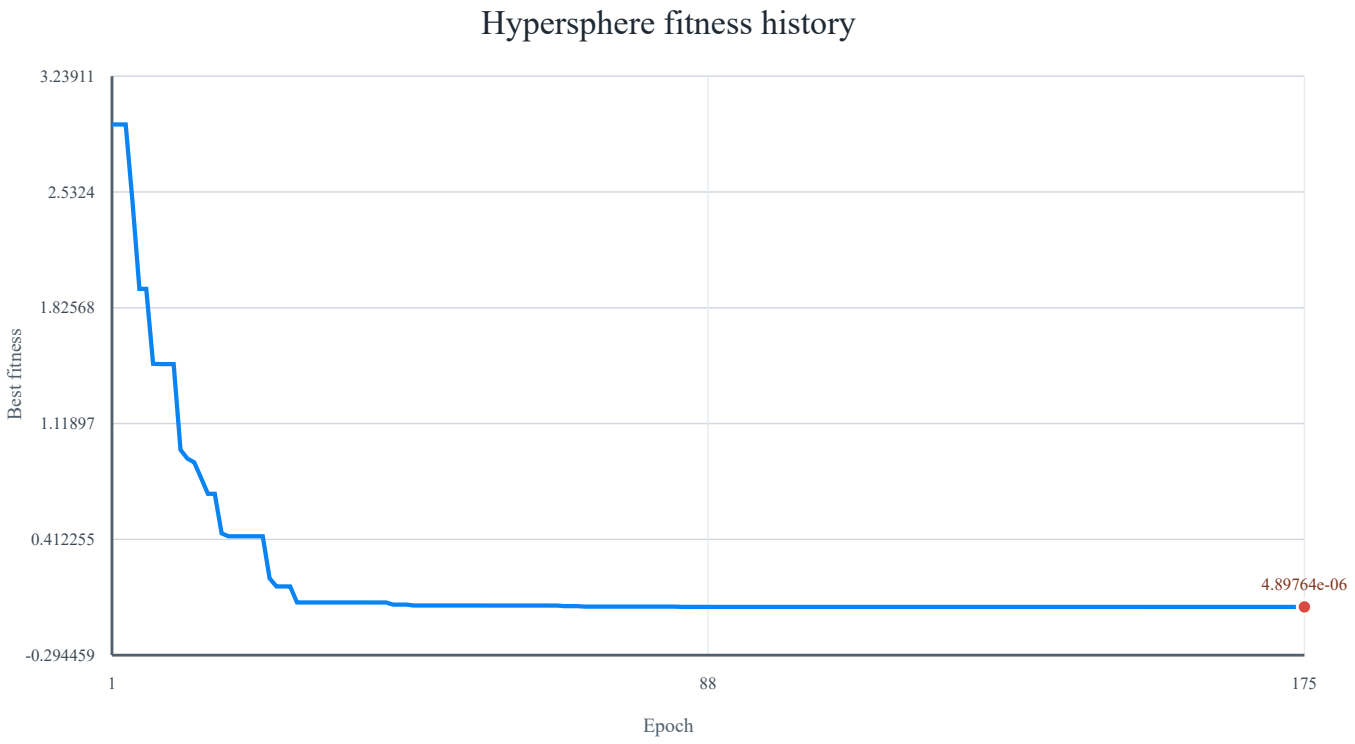

Wykres 3

Wykres dla selekcji `roulette`

Kluczowa wartość configu względem pozostałych

- selection_method = roulette

Co widać na wykresie

- Rownież schodkowy przebig, ale dłuższy
- Dojście bliskie rozwiązania dopiero koło 80 epoki

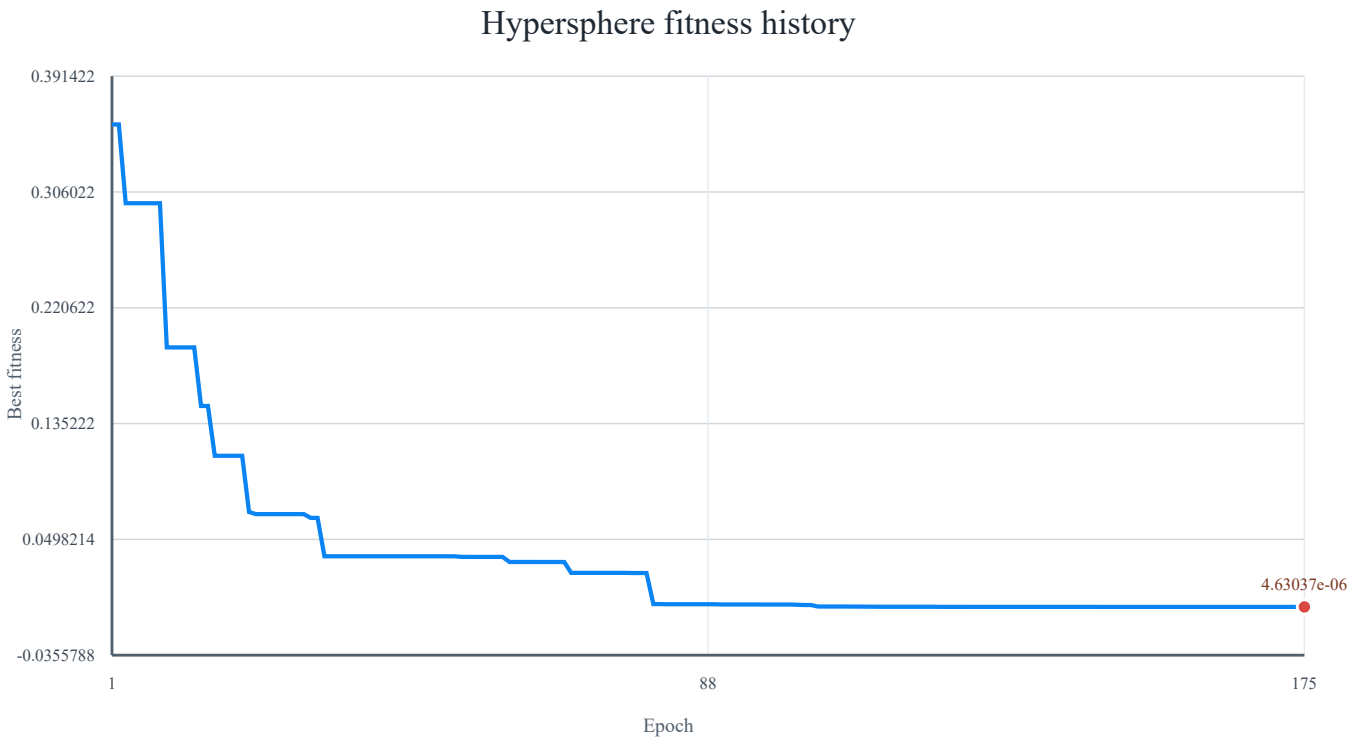

5. Porównanie wyników dla różnych konfiguracji algorytmu

Implementacja udostępnia parametry, które bezpośrednio wpływają na jakość i szybkość zbieżności

- Metoda selekcji: tournament, best, roulette
- Metoda krzyżowania (oraz jej prawdopodobieństwo): single_point, two_point, uniform, granular
- Metoda mutacji (oraz jej prawdopodobieństwo): single_point, edge, two_point
- Prawdopodobieństwo inwersji
- Rozmiar populacji
- Liczba epok
- Rozmiar elity

Kierunek porównania konfiguracji

- Większa populacja zwykle poprawia eksplorację kosztem czasu obliczeń
- Większa liczba epok zwykle poprawia końcowy wynik kosztem czasu
- Selekcja tournament może dawać stabilne postępy przy poprawnym doborze rozmiaru turnieju. W naszym eksperymencie zbiegała ona najszybciej do poprawnego rozwiązania, natomiast miała potem problem ze znalezniem dokładniejszego rozwiązania.
- Zbyt wysoka mutacja pogarsza stabilizację rozwiązania
- Elityzm przyspiesza utrzymanie dobrych osobników ale może ograniczać różnorodność

Zestawienie końcowych wyników

Przebieg	selection_method	best_fitness	elapsed_seconds
Tournament	tournament	2.5991082520405703e-05	0.1211451
Best	best	4.897643319657252e-06	0.1033877
Roulette	roulette	4.630370506111484e-06	0.1125114

Wniosek z samej wartości końcowej

- Najlepszy wynik końcowy uzyskał `roulette`
- Drugi wynik uzyskał najszybszy `best`
- Najsłabszy wynik końcowy uzyskał `tournament`, który był również najwolniejszy

Wnioski z porównania

- Sama zmiana metody selekcji istotnie zmieniła dynamikę zbieżności
- Selekcja `best` i roulette dały wyraźnie lepsze wartości końcowe niż tournament
- Tournament miał najszybszy progress, jednak potem miał problem nadgonić
- `roullete` z najlepszym wynikiem zbiegało najwolniej, mimo to osiągnęło najlepszy wynik końcowy (ale nie dużo lepszy niż `best`)

6. Podsumowanie i analiza błędów

Podsumowanie

- Aplikacją GUI do optymalizacji funkcji Hypersphere algorytmem genetycznym
- Formularz do konfiguracji funkcji, zapis do plików, oraz generowanie wykresu.

Analiza błędów i ryzyk

- Jakość wyniku zależy od doboru parametrów i losowości procesu ewolucyjnego
- Praca z liczbami zmiennoprzecinkowymi (overflow itp.)
- Nie implementowaliśmy unit testów